項目	狀態	截止時間	權重	成績
◆ 作業三 測驗	已通過	1月20日 15:59 CST	50%	100%

2.

此敘述為 True

proof:

分成兩種狀況討論:

- ①當 y 與 w^T x 同號,err(w)= max(0, ¬yw^T x)=0:
 PLA:此時分類正確,PLA 演算法並不會改動 weight,即 w_{t+1}= w_t+0
 SGD:此時梯度為 0,w_{t+1}= w_t-0= w_t+0,結果與 PLA 相同
- ②當 y 與 w^T x 異號,err(w)= max(0, ¬yw^T x)= -yw^T x:
 PLA:此時分類錯誤,PLA 演算法改動 weight,即 w_{t+1}= w_t+yx
 SGD:此時梯度為-yx,w_{t+1}= w_t-(-yx)= w_t+yx,結果與 PLA 相同

可知在使用 SGD 的情況下,PLA 的 error function 可以是 $err(w) = max(0, -yw^Tx)$

3.

把
$$E(u+\Delta u, v+\Delta v)$$
 衰勒展開至二階 形式 $E(u+\Delta u, v+\Delta v) = E(u,v) + \frac{\partial E(u,v)}{\partial v} \Delta u + \frac{\partial E(u,v)}{\partial v} \Delta v + \frac{\partial E($


$$\frac{1}{N+K} \left(\sum_{n=1}^{K} (y_n - w^T x_n)^2 + \sum_{k=1}^{K} (w^T x_k - y_k)^2 \right) \\
= \frac{1}{N+K} \left(\sum_{n=1}^{K} (w^T x_n - y_n)^2 + \sum_{k=1}^{K} (w^T x_k - y_k)^2 \right) \\
= \frac{1}{N+K} \left(\sum_{n=1}^{K} (x_n^T w - y_n)^2 + \sum_{k=1}^{K} (w^T x_k - y_k)^2 \right) \\
= \frac{1}{N+K} \left(\sum_{n=1}^{K} (x_n^T w - y_n)^2 + \sum_{k=1}^{K} (w^T x_n^T w - y_k)^2 \right) \\
= \frac{1}{N+K} \left(\sum_{n=1}^{K} (x_n^T w - y_n)^2 + \sum_{k=1}^{K} (w^T x_n^T w - y_k)^2 \right) \\
= \frac{1}{N+K} \left(\sum_{n=1}^{K} (x_n^T w - y_n)^2 + \sum_{k=1}^{K} (w^T x_n^T w - y_k)^2 \right) \\
= \frac{1}{N+K} \left(\sum_{n=1}^{K} (x_n^T w - y_n)^2 + \sum_{k=1}^{K} (w^T x_n^T w - y_n^T x_n^T y_n^T w - y_n^T x_n^T x_n^T y_n^T w - y_n^T x_n^T x_n^T x_n^T w - y_n^T x_n^T x_n^T x_n^T w - y_n^T x_n^T x_n^T x_n^T x_n^T x_n^T x_n^T w - y_n^T x_n^T x$$

對上式作偏微为可得:


走上式為O可得:

$$(\tilde{\chi}^{T}\tilde{\chi} + \tilde{\chi}^{T}\chi)^{T}(\tilde{\chi}^{T}\tilde{\chi} + \tilde{\chi}^{T}\chi) = (\tilde{\chi}^{T}\chi)^{T}(\tilde{\chi}^{T}\chi + \tilde{\chi}^{T}\chi)$$

$$I \cdot \vec{k} = \vec{\chi} \in I_K = \vec{\chi} \cdot \vec{\chi} \circ \in I_K = \vec{\chi} \cdot \vec{\chi} \circ \in I_K = \vec{\chi} \cdot \vec{\chi} \circ \in I_K = I_K \cdot \vec{\chi} \circ \vec{$$



Stochastic gradient descent 的 error rate 基本上維持在 0.45 左右,相反的,Gradient descent 則一路下降直到 T=2000,且似乎還有再往下降的趨勢



曲線基本上與第7題一樣,但在相同 T 的情況,不管是 Stochastic gradient descent 還是 Gradient descent,Ein 均比 Eout 來的低(下方是比較圖)

